1. Vektori X1, X2, …, Xn su linearno zavisni ako i samo ako je neki od tih vektora nelinearna kombinacija preostalih:
   True
   False

2. Baza vektorskog prostora je najmanji linearno nezavisnih vektora iz kojeg se može generirati čitav taj prostor, odnosno pomoću kojeg se može izraziti bilo koji vektor tog prostora:
   True
   False

3. FAKTORIZACIJA MATRICA je postupak kojim danu matricu rastavljamo na zbroj matrica:
   True
   False

4. Rang vektorskog sustava r je broj linearno zavisnih vektora tog sustava:
   True
   False

5. U grafičkoj metodi funkciji cilja može postići optimum (imati optimalno rješenje): (jedan ili više)
   a) u jednom od vrhova konveksnog skupa koji predstavlja zajedničko područje rješenja
   b) najčešće unutar zajedničkog područja rješenja, no postoje slučajevi kada se optimum postiže i izvan tog područja
   c) u bilo kojoj unutrašnjoj točki konveksnog skupa koji predstavlja zajedničko područje rješenja
   d) po jednoj strani (rubu) konveksnog skupa koji predstavlja zajedničko područje rješenja

6. Ako je skup mogućih rješenja problema linearnog programiranja nije konveksni poliedar ekstrem može i ne postojati, ali ako postoji, postiže se također u jednoj od ekstremnih točaka ili u više njih:
   True
   False

7. Svi dualni problemi linearnog programiranja po svojoj vrste će biti standardni (bez obzira kakav je orginalni problem):
   True
   False

8. Dual dualnog problema je orginalni problem:
   True
   False

9. Pretvaranjem standardnog oblika problema za minimum u kanonski oblik probleme artificijelne varijable u funkciji cilja množe se sa +M.

10. Pretvaranje standardnog problema oblika LP-a za maksimum u kanonski oblik izvodi se na način da se nejednadžbe pretvore u jednadžbe na način da se lijevoj strani nejednažba nadoda nova varijabla ui koja predstavlja neutrošenu količinu određenog resursa (onog u čije se ograničenje ona dodaje).

11. Svi dualni problemi linearnog programiranja po svojoj vrsti će biti opći (bez obzira kakav je originalni problem):
    True
    False

12. Pod svojstvima determinante odaberite NETOČNU tvrdnju:
    //odaberi jednu stvar
    a) Determinanta ne mijenja svoju vrijednost ako retke zamijenimo stupcima.
    b) Determinanta mijenja predznak ako dva susjedna retka/stupca zamijene mjesta.
    c) Determinanta koja sadrži stupac/redak koji sadrže sve nule, je jednaka nuli
    d) Determinanta s dva jednaka retka/stupca je jednaka jedinici.
    e) Determinanta kojoj je redak/stupac linearna kombinacija redaka (stupaca) je linearna kombinacija determinanti
    f) Determinanta se množi skalarom tako da elemente bilo kojeg retka/stupca množimo tim skalarom. Obratno, zajednički faktor nekog retka/stupca se može izlučiti pred determinantu.
    g) Ako se dvije determinante razlikuju samo u jednom retku/stupcu, one se zbrajaju tako da se zbroje stupci/reci u kojima se razlikuju, a ostali stupci/reci ostaju nepromijenjeni

13. Standardni problem minimuma ima sva ograničenja osim uvjeta nenagativnosti tipa:
    //odaberi jednu stvar
    a) jednadžbe
    b) nejednadžbe manje ili jednako
    c) nejednadžbe veće ili jednako
    d) nejednadžbe manje ili jednako i nejednadžbe veće ili jednako

14. Kao rješenje problema linearnog programiranja koji se bave traženjem optimalnog rješenja pogodne su samo vršne točke konveksnog skupa:
    True
    False

15. Zadatak korištenja grafičke metode za probleme linearnog programiranja je od beskonačno mnogo točaka izabrati samo jednu optimalnu od njih za koju funkcija cilja ima maksimalnu ili minimalnu vrijednost:
    True
    False

16. Ako je r rang vektorskog sustava: a_1, a_2, …, a_r i ako su u njemu vektori a_{i1}, a_{i2}, …, a_{ir} linearno zavisni tada se bilo koji vektor sustava može izraziti kao linearno kombinacija R linearno nezavisnih vektora i to jednoznačno:
    True
    False

17. Matrični zapis SPLP za maksimum je:
    //Izaberi jedan
    a) $C^T X$ → Max, uz uvjete AX <= B, X>=0
    b) CX → Max, uz uvjete AX <= B, X>=0

18. Broj vektora u bazi jednak je minimalnom broju linearno zavisnih vektora u tom prostoru i jednak je dimenziji prostora:
    True
    False

19. Grafičku metodu možemo primijeniti za rješavanje bilo kojeg problema LP problema s dvije varijable odlučivanja:
    True
    False

20. Svi dualni problemi LP po svojoj su vrsti kanonski (bez obzira kakav je originalni problem), pa će standardni problem za minimum dualni (suprotan) problem biti kanonski problem za maksimum:
    True
    False

21. Dopunska varijabla „u" predstavlja količinu pridodanog/neutrošenog resursa koja je izražena nekim mjernim jedinicama (težinskim, vremenskim, komadnim, prostornim ili drugo), a funkcija cilja govori o ostvarenim prihodima/troškovima – dakle novcu. To znači da se treba „isključiti" utjecaj dopunske varijable na funkciju cilja u kojoj mora biti, stoga se u funkciji cilja dopunske varijable množe s nulom.

22. Transportni problem je problem raspoređivanja tereta uz potpuno iskorištenje kapaciteta nekih ishodišta i svih kapaciteta odredišta.
    True
    False

23. Zatvoreni transportni problem:
    //Izaberi jedan
    a) Ima jednaku sumu kapaciteta ishodiša i kapaciteta odredišta
    b) ima veću sumu kapaciteta odredišta od kapaciteta ishodišta
    c) Definira se temeljem zadanog skupa ograničenja
    d) Ima veću sumu kapaciteta ishodiša od kapaciteta odredišta

24. Sve metode za početno raspoređivanje tereta daju početni raspored jednake kvalitete:
    True
    False

25. Rang transportnog problema je broj linearno zavisnih vektora koji opisuje cijeli sustav:
    True
    False

26. Transportni problem je problem raspoređivanje homogenog tereta iz više ishodišta u više odredišta uz minimalne ukupne troškove:
    True
    False

27. Otvoreni transportni problem je po svojoj vrsti kakav problem linearnog programiranja:
    //Izaberi jedan
    a) Opći problem LP
    b) Kanonski problem LP
    c) Standardni problem LP

28. Metode za početno raspoređivanje tereta daju početni raspored različite kvalitete:
    True
    False

29. Metode za traženje optimalnog rješenja razlikuju se u primjeni po broju iteracija koje je potrebno napraviti:
    True
    False

30. Ako je skup mogućih rješenja problema linearnog programiranja konveksni poliedar, tada ekstrem postoji i postiže se u jednoj od ekstremnih točaka. Ako se ekstrem postiže u dvije ekstremne točke, tada se postiže i za svaku njihovu konveksnu kombinaciju tj. za svaku točku na spojnici tih dviju ekstremnih točaka:
    True
    False

31. Među linearno nezavisnim vektorima ne može se nalaziti NULA-VEKTOR:
    True
    False

32. Ako u skupu uvjeta LP problema s dvije varijable nalaze i dvije jednadžbe 4, tada:
    //Izaberi jedan
    a) LP problem može imati optimalno rješenje ako se pripadni pravci sijeku unutar zajedničkog područja rješenja
    b) LP problem ima beskonačno mnogo rješenja
    c) LP problem u tom slučaju ne može imati optimalno rješenje
    d) LP problem ima optimalno rješenje ako se pripadni pravci sijeku bilo gdje
    e) LP problem ima rješenje ako se pripadni pravci sijeku unutar zajedničkoj područja rješenja

33. Svaki problem maksimuma pridružen je i određeni problem minimuma koji se još naziva dual originalnog problema

34. Transportni problem je problem raspoređivanje tereta iz više ishodišta u više odredišta:
    True
    False

35. Vogelova metoda je metoda:
    //odaberi jedan
    a) koja ne vodi računa o troškovima već samo o kapacitetima
    b) koja vodi računa o troškovima i kapacitetima uz poštivanje najboljih omjera troškova
    c) koja vodi računa o troškovima i kapacitetima
    d) koja vodi računa samo o troškovima, ali ne i o kapacitetima

36. Transportni problem je problem raspoređivanja homogenog tereta iz
{
//izaberi jedan
manje ishodišta u više odredišta
više ishodišta u manje odredišta
više ishodišta u više odredišta
jednaki broj ishodišta i odredišta
} uz potpuno iskorištenje kapaciteta i minimalne ukupne troškove.

37. Zatvoreni transportni problem:
//Izaberi jedan
a) Definira se temeljem zadanog skupa ograničenja
b) Ima jednaku sumu kapaciteta ishodišta i kapaciteta odredišta
c) Ima veću sumu kapaciteta odredišta od kapaciteta ishodišta
d) Ima veću sumu kapaciteta ishodišta od kapaciteta odredišta

38. Metode za traženje optimalnog rješenja tereta određuju uvijek jedinstveno optimalno rješenje transportnog problema:
True
False

39. Dual otvorenog transportnog problema je problem LP kojeg definira skup ograničenja zadan kao
//Izaberi jedan (nez šta se nudi vamo)
a) Manje ili jednako

40. Metoda minimalnih troškova je metoda:
//izaberi jedan
a) koja zadovoljava originalni skup ograničenja odredišta
b) koja zadovoljava originalni skup ograničenja ishodišta i odredišta
c) koja zadovoljava originalni skup ograničenja ishodišta
d) koja zadovoljava dualni skup ograničenja

41. Ekstremne točke skupa mogućih rješenja su ustvari bazična rješenja odgovarajućeg problema linearnih jednadžbi koji pripada tom problemu linearnog programiranja.

42. Dual standardnog problema maksimuma je opći problem minimuma:
True
False

43. Svaka baza prostora R^n sastoji se od točno n linearno zavisnih vektora.
True
False

44. Dual dualnog problema LP-a je originalni problem LP-a.

45. Matrice A i B možemo sumirati samo ako nisu istoga reda.
    True
    False

46. Vektori X1, X2, …, Xn su linearno zavisni ako i samo ako je neki od tih vektora linearna kombinacija preostalih:
    True
    False

47. Optimalno rješenje u standardnom problemu linearnog programiranja za minimum koristeći simpleks algoritam dobiva se na način da su sve vrijednosti u retku dj jednake nuli, a u retku Zj-Cj ispod strukturalnih i ispod dopunskih varijabli
    //izaberi jedan (neman vidljive opcije)
    a)Nema pozitivnih vrijednosti – možda nije ponuđeno(smije bit negativni ili nula)

48. Sva ograničenja u standardnom problemu za maksimum osim uvjeta nenagativnosti su nejednadžbe tipa veće ili jednako:
    True
    False

49. Neki podskup K prostora E nazivamo konveksnim skupom ako dužina (a,b) određena bilo kojim točkama a i b iz podskupa K, ne leži u K:
    True
    False

50. Svakom problemu maksimuma pridružen je i određeni problem minimuma koji se još naziva dual originalnog problema.

51. Vektori X1, X2, …, Xn su linearno nezavisni ako i samo ako je neki od tih vektora linearna kombinacija preostalih:
    True
    False

52. FAKTORIZACIJA MATRICA je postupak kojim danu matricu rastavljamo na produkt matrica:
    True
    False
53. Ako je skup mogućih rješenja problema linearnog programiranja nije konveksni poliedar ekstrem uvijek postoji i postiže se u jednoj od ekstremnih točaka ili u više njih:

True
False

54. X+(Y+Z)=(X+Y)+Z je svojstvo pod nazivom Asocijativnost.

55. Konveksni poliedar je onaj konveksni skup koji je ograničen i ima ograničen broj ekstremnih točaka tjemena:
    True
    False

56. Množiti se mogu samo takve matrice A i B koje zadovoljavaju uvjet – broj redaka prvog faktora A mora biti jednak broju redaka drugog faktora B:
    True
    False

57. X+y=y+x je svojstvo pod nazivom komutativnost.

58. Kod standardnog problema za minimum da bi se razvio kanonski oblik, nejednadžbe „veće ili jednako“ iz standardnog oblika pretvorene u jednadžbe na način da je na lijevoj strani nejednadžbe
    {
    //izaberi jedan
    a} podijeljena
    b} pridodana
    c} oduzeta
    d} pomnožena
    }
    nova varijabla u, koja predstavlja količinu određenog resursa koja je naknadno pridodana početnoj zadanoj količini.

59. Ako je na jednoj strani problem maksimuma (ostvarenje profita) onda je s druge strane – suprotni problem – problem minimuma (npr. Troškova) čija su sva ograničenja tipa manje ili jednako:
    True
    False

60. Transportni problem je problem raspoređivanje tereta iz više ishodišta u jedno odredište:
    True
    False

61. Dual zatvorenog transportnog problema je problem LP kojeg definira skup ograničenja zadan kao skup nejednadžbe <=.

62. Metode za početno raspoređivanje terete koriste se zbog toga što se transportni problem ne može riješiti „od nule“ nekim drugim metodama:
True –
False – A, I

63. Zatvoreni put je linearna kombinacija linearno nezavisnih vektora:
True – M, A
False